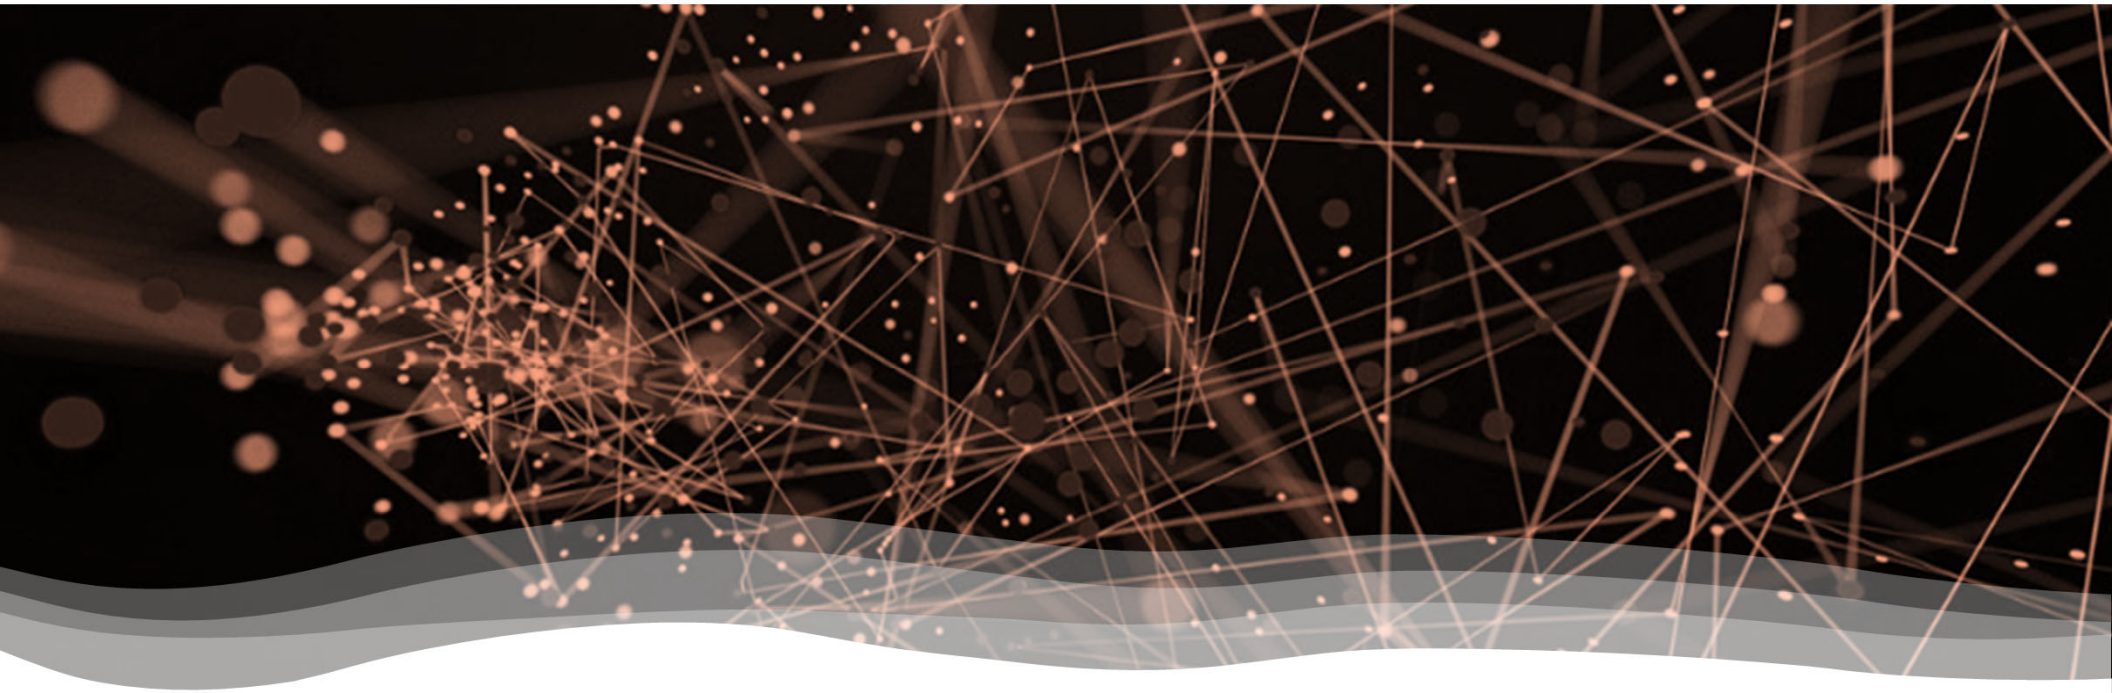

Clasificación Automática de Quejas Financieras con Deep Learning

UTEC- Técnicas de Inteligencia Artificial: Deep Learning

Profesora: Bruna de Vargas
Alumnos: Aranda Andrea, Biardo Yuri, Sambucetti Mariana

Problema y Contexto

Desafío:
El CFPB (Consumer Financial Protection Bureau) recibe diariamente un enorme volumen de quejas sobre productos financieros.

Clasificación manual: costosa, lenta y propensa a inconsistencias.

Lenguaje variado: cada consumidor escribe de forma única, dificultando enfoques tradicionales.

Objetivo:
Desarrollar un clasificador automático que asigne la categoría correcta de producto financiero a partir del texto de la queja.

5
Categorías

162K
Quejas

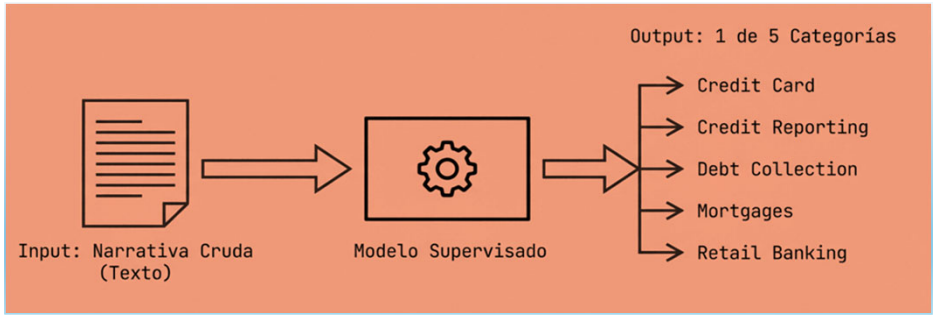

Solución Propuesta: DistilBERT

¿Por qué DistilBERT?

Versión optimizada de BERT: mantiene el 97% del rendimiento con solo el 60% de los parámetros (66M vs 110M).
Ideal para entrenamiento en Google Colab.

Arquitectura Transformer

Self-attention: procesa todas las palabras simultáneamente

Contextualización: entiende relaciones entre palabras

Superioridad: vs modelos secuenciales (RNN, LSTM)

Fine-Tuning

Partimos de un modelo pre-entrenado con millones de textos y lo adaptamos a nuestra tarea específica:

1. Capa de clasificación con 5 salidas
2. Entrenamiento con datos de quejas
3. Pesos de clase para desbalance

Dataset y Preprocesamiento

Consumer Complaints Dataset (Kaggle)
162,411 quejas reales del CFPB con narrativa (texto libre) y categoría de producto

Categoría	Cantidad	%	Peso
credit_reporting	91,179	56.14 %	Bajo
debt_collection	23,150	14.25 %	Medio
mortgages_and_loans	18,990	11.69 %	Medio-alto
credit_card	15,566	9.58%	Alto
retail_banking	13,536	8.33%	Alto

Preprocesamiento:

1. **Limpieza**: eliminación de valores vacíos
2. **Tokenización**: DistilBERT tokenizer (sub-palabras → IDs)
3. **Truncamiento**:256 tokens (94.6% de quejas)
4. **Encoding**: Categorías a números (0-4)
5. **División**: 80% train / 10% val / 10% test
6. **Estratificación**: Misma proporción en cada conjunto.

Configuración del Entrenamiento

Hiperparámetros:

Parámetro	Valor	Justificación
Epochs	3	Converge sin sobreajuste
Batch size	16	Óptimo para Colab
Learning rate	2e-5	Estándar para fine-tuning de BERT
Max length	256 tokens	Cubre 94.6% de las quejas
Weight decay	0.01	Regularización estándar

Desafío principal: desbalance de clases.

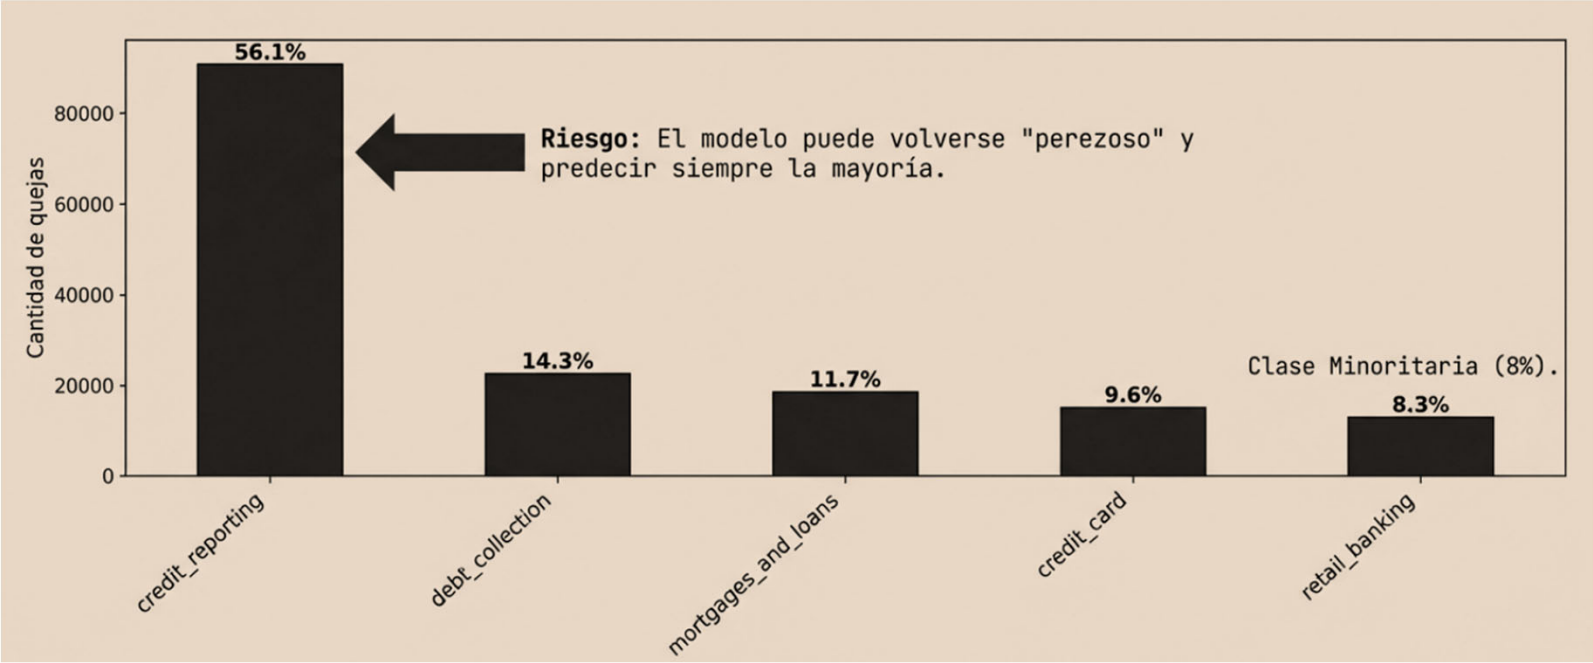

Enfoque Clave: Weighted Trainer
Implementación de pesos de clase inversamente proporcionales para manejar el desbalance.
Las categorías minoritarias tienen mayor peso en la función de pérdida (CrossEntropyLoss).
Sin intervención el modelo sufriría un sesgo severo hacia la clase mayoritaria.

Resultados Generales

Aspectos Destacados:

89.89%

ACCURACY

9 de cada 10 quejas clasificadas correctamente

0.87

F1-SCORE MACRO

Rendimiento balanceado entre todas las categorías

- Diferencia mínima entre F1 macro (0.87) y weighted (0.90): los pesos de clase funcionaron
- Resultados sólidos considerando el fuerte desbalance del dataset (56% en una sola categoría)

Desempeño por categoría

Categoría	Precision	Recall	F1-Score	Support
credit_card	0.83	0.82	0.82	1,557
credit_reporting	0.93	0.95	0.94	9,118
debt_collection	0.85	0.80	0.82	2,315
mortgages_and_loans	0.88	0.83	0.85	1,899
retail_banking	0.89	0.90	0.89	1,353
Macro avg	**0.87**	**0.86**	**0.87**	**16,242**

✓ Mejor desempeño

credit_reporting (F1: 0.94) - mayor cantidad de datos. retail_banking (F1: 0.89) - excelente resultado con solo 8% de los datos, evidencia de la efectividad de los pesos de clase.

⚠ Mayor dificultad

credit_card y debt_collection (F1: 0.82) - vocabulario compartido dificulta la distinción. Ambas categorías usan terminología financiera similar.

Análisis de errores:

Dónde se confunde el modelo?

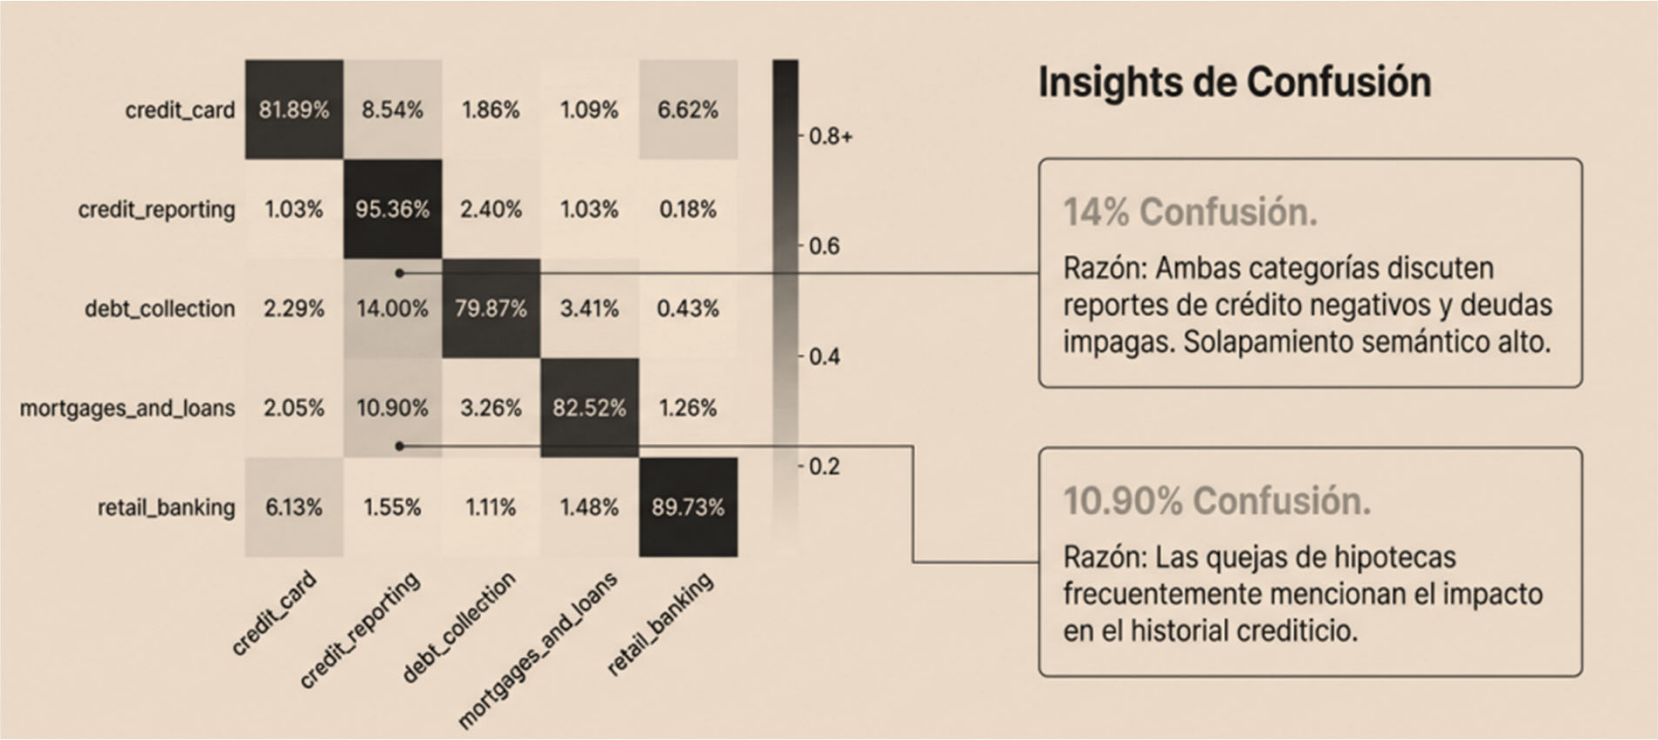

Los errores son semánticamente razonables: las categorías confundidas comparten vocabulario y conceptos financieros

Análisis de Entrenamiento:

✓ **Sin señales de overfitting: mejora constante sin degradación**

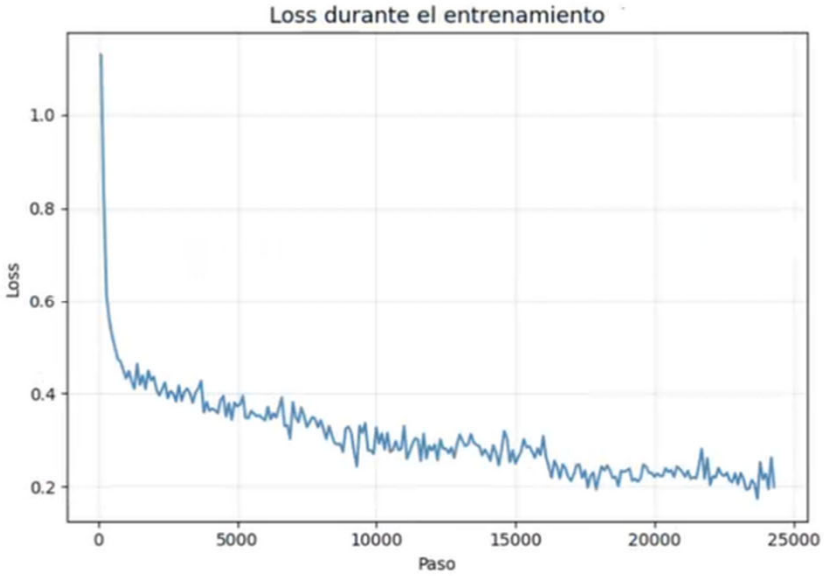

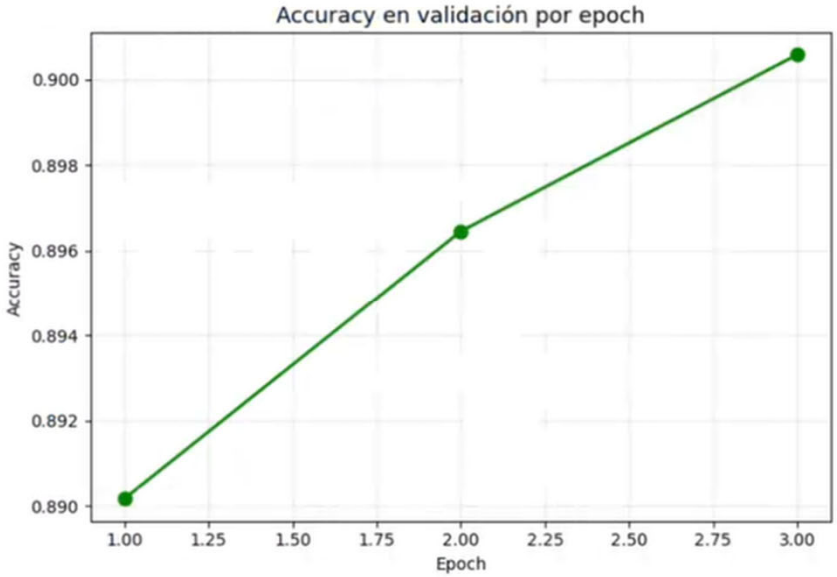

Evolución del Training Loss

Inicio	1.15
Epoch 1	0.45
Epoch 2	0.28
Epoch 3	0.20

Accuracy en Validación

Epoch 1	89.0%
Epoch 2	89.6%
Epoch 3	90.0%

Conclusiones y Trabajo Futuro

Logros Principales

- El modelo DistilBERT fine-tuned alcanzó un 89.89% de accuracy y F1 macro de 0.87.
- Los pesos de clase resolvieron efectivamente el desbalance de datos.
- Errores del modelo son semánticamente razonables (vocabulario compartido).
- Entrenamiento eficiente en Google Colab sin problemas de recursos.

Trabajo Futuro

Modelo más grande
Probar bert-base-uncased (110M parámetros)
Mayor contexto
Subir max_length a 512 tokens (5.4% de quejas truncadas)
Data augmentation
Generar ejemplos sintéticos para clases minoritarias

Limitaciones

- Vocabulario compartido entre categorías financieras
- Truncamiento en 5.4% de quejas más largas
- Solo inglés (distilbert-base-uncased)
- Restricciones de memoria de Colab

Gracias